
TRABAJO PRÁCTICO 2.2 - GENERADORES DE NÚMEROS PSEUDOALEATORIOS DE DISTINTAS DISTRIBUCIONES DE PROBABILIDAD.

Danteo, Elías

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
elias.danteo.tomas@hotmail.com

Cosentino, Lucio N.

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
luciocosen@gmail.com

De Bernardo, Aarón

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
aarondebernardo@gmail.com

Fernandez Da Silva, Joaquín C.

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
joaquinfds13@gmail.com

Malizani, Juan Pablo

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
juampi123.m@gmail.com

Pastorino, Juan Jose

Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
juanjosepastorino@gmail.com

May 21, 2025

ABSTRACT

El presente trabajo tiene por objetivo profundizar en el estudio y la implementación de generadores de números pseudoaleatorios para múltiples distribuciones de probabilidad, pilares esenciales en la simulación computacional. A partir de un generador uniforme validado, se desarrollarán en Python 3.x métodos de transformación (inversa, rechazo) para obtener muestras de distribuciones continuas (uniforme, exponencial, gamma, normal) y discretas (Pascal, binomial, hipergeométrica, Poisson y empírica). Cada algoritmo será sometido a un conjunto de pruebas estadísticas que evaluarán la uniformidad e independencia de las secuencias generadas, además de medir el tiempo de generación por muestra como indicador de eficiencia computacional. Los resultados se presentarán mediante tablas y gráficos que faciliten el análisis cuantitativo y comparativo de precisión y rendimiento. Finalmente, se extraerán conclusiones sobre las fortalezas y limitaciones de cada método en un contexto práctico de simulación, considerando aspectos de reproducibilidad y costo computacional.

Keywords Simulación · Generadores pseudoaleatorios · Transformación de distribuciones · Pruebas estadísticas

1 Introducción

Anteriormente se validó satisfactoriamente un generador de números pseudoaleatorios uniformes en el intervalo $(0,1)$, demostrando su idoneidad para aplicaciones básicas de simulación. No obstante, la mayoría de los experimentos estocásticos requieren muestras de distribuciones específicas [tanto continuas (exponencial, gamma, normal) como discretas (Pascal, binomial, hipergeométrica, Poisson y empírica)] para modelar fenómenos como tiempos de espera, conteos de eventos o ensayos de Bernoulli. El desafío actual consiste en “redescubrir” e implementar los métodos clásicos que transforman secuencias uniformes en muestras de otras distribuciones, tal como describe Thomas Naylor en su obra sobre técnicas de simulación en computadoras. En particular, se implementarán en Python 3.x las técnicas indicadas (Método Inverso, Método de Rechazo). Cada uno de estos algoritmos será sometido a un riguroso proceso de

testeo. De este modo, se evaluarán tanto la fidelidad estadística como la eficiencia computacional de cada generador, ofreciendo criterios sólidos para seleccionar el método más adecuado según los requisitos de precisión, velocidad y reproducibilidad en simulaciones prácticas.

2 Marco Teórico

2.1 Distribuciones Continuas de Probabilidad

Una distribución continua de probabilidad describe cómo se reparten las probabilidades en un conjunto de valores, típicamente en un intervalo del conjunto de los números reales (por ejemplo, de 0 a 1 o de $-\infty$ a ∞). En lugar de asignar probabilidades a valores puntuales, lo hace sobre intervalos, utilizando una *función de densidad de probabilidad* (PDF).

Por ejemplo, la probabilidad de que una variable aleatoria continua tome exactamente un valor, como $X = 3$, es 0; lo que importa es la probabilidad de que esté entre dos valores:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

2.1.1 Distribución Uniforme

La distribución uniforme continua modela una variable que tiene igual probabilidad en todos los puntos de un intervalo $[a, b]$, con $a < b$. Su función de densidad es:

$$f(x) = \frac{1}{b-a}, \quad x \in [a, b].$$

Momentos

$$\mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

Función acumulada

$$F(x) = \begin{cases} 0 & \text{si } x < a \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } x > b \end{cases}$$

Aproximaciones y usos La uniforme continua es base para la generación de otras distribuciones mediante transformación. Se usa para modelar incertidumbre total entre límites conocidos, en simulaciones, juegos, y muestreo aleatorio. Es esencial en métodos Monte Carlo y generación de pseudoaleatoriedad.

2.1.2 Distribución Exponencial

La distribución exponencial modela el tiempo entre eventos en un proceso de Poisson con tasa $\lambda > 0$. Es continua, no simétrica, y decae exponencialmente hacia la derecha. Su función de densidad es:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

Momentos

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Función acumulada

$$F(x) = P(X \leq x) = 1 - e^{-\lambda x}, \quad x \geq 0.$$

Aproximaciones y usos La exponencial es el caso continuo más simple de tiempo de espera y es la base de procesos de Poisson. Su propiedad de ***falta de memoria*** la hace única: $P(X > s+t \mid X > s) = P(X > t)$. Es común en teoría de colas, confiabilidad, modelos de fallas y simulación de eventos aleatorios.

2.1.3 Distribución Gamma

La distribución gamma modela tiempos de espera hasta que ocurren α eventos en un proceso de Poisson con tasa β . Es continua, no negativa y asimétrica. Su densidad está dada por:

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0, \alpha, \beta > 0.$$

Momentos

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}.$$

Función acumulada

$$F(x) = P(X \leq x) = \frac{1}{\Gamma(\alpha)} \int_0^{\beta x} t^{\alpha-1} e^{-t} dt.$$

Se expresa mediante la función gamma incompleta. No tiene forma cerrada para $\alpha \notin \mathbb{N}$, pero es tabulada y computada numéricamente.

Aproximaciones y usos Para α grande, la gamma se aproxima por una normal. Es útil en modelado de tiempos hasta eventos múltiples, fiabilidad, colas, y distribución de ingresos. La exponencial ($\alpha = 1$) y la chi-cuadrado ($\alpha = k/2$, $\beta = 1/2$) son casos particulares.

2.1.4 Distribución Normal

La distribución normal (o gaussiana) modela fenómenos continuos simétricos alrededor de una media μ , con dispersión determinada por una desviación estándar σ . Su densidad está dada por:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Momentos

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2.$$

Función acumulada

$$F(x) = P(X \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{(x-\mu)/\sigma} e^{-t^2/2} dt.$$

No posee forma cerrada; se evalúa numéricamente o con tablas estandarizadas ($Z \sim \mathcal{N}(0, 1)$).

Aproximaciones y usos La normal aparece como límite de muchas distribuciones (teorema central del límite). Aproxima bien distribuciones de suma de muchas variables independientes. Se usa en inferencia estadística, física, ingeniería, economía, y donde el “ruido” sea natural y acumulativo.

2.2 Distribuciones Discretas de Probabilidad

Se encuentra definido un número muy significativo de distribuciones de probabilidad para variables aleatorias que solamente toman valores discretos, esto es, enteros no negativos. La distribución acumulativa de probabilidad para una variable aleatoria discreta X se define como:

$$F(x) = P(X \leq x) = \sum_{k=0}^x f(k)$$

donde $f(x)$ es la frecuencia o función de probabilidad de X , definida por valores enteros x tales que

$$F(x) = P(X = x)$$

para $x = 0, 1, 2, \dots$

Las distribuciones discretas de probabilidad son muy útiles cuando se las emplea como modelos estocásticos para ciertos procesos de conteo, ya sea sobre muestras finitas o no finitas, donde la presencia o ausencia de un atributo dicotómico está gobernada por el azar. Desde un punto de vista empírico las distribuciones discretas pueden también ocurrir como resultado de redondear medidas continuas sobre una escala discreta. Sin embargo, estrictamente hablando, las distribuciones discretas de probabilidad resultan ser los modelos más apropiados para fenómenos aleatorios cuando los valores de las variables se pueden determinar por medio de procesos de conteo.

2.2.1 Distribución de Pascal (Binomial Negativa)

La distribución de Pascal, también conocida como binomial negativa, modela el número de fracasos x que ocurren antes de obtener r éxitos en una secuencia de ensayos de Bernoulli independientes, donde cada ensayo tiene probabilidad p de éxito.

Su función de masa de probabilidad es:

$$P(X = x) = \binom{x+r-1}{x} (1-p)^x p^r, \quad x \in \mathbb{N}_0$$

Donde:

- r : Número de éxitos deseados.
- p : Probabilidad de éxito en cada ensayo (con $0 < p < 1$).
- x : Número de fracasos antes de alcanzar r éxitos.

Esta distribución es útil en contextos donde interesa contar la cantidad de fallos antes de lograr una cantidad fija de éxitos, como en procesos repetitivos con resultados dicotómicos (éxito o fracaso).

2.2.2 Distribución Binomial

La distribución binomial modela el número de éxitos en n ensayos de Bernoulli independientes con probabilidad de éxito p . Se define mediante la pmf:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Momentos

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p).$$

Función acumulada

$$F(k) = P(X \leq k) = \sum_{i=0}^k \binom{n}{i} p^i (1-p)^{n-i}.$$

Aproximaciones y usos Para n grande y p cercano a 0 o a 1, la binomial se aproxima bien con Poisson ($\lambda = np$). Si $np(1-p)$ es grande (>10), la aproximación normal es adecuada. Se usa en modelado de éxitos/fracaso en calidad, ensayos clínicos, control de procesos y muestreo.

2.2.3 Distribución Hipergeométrica

La distribución hipergeométrica modela la probabilidad de obtener exactamente x éxitos en una muestra de tamaño n , seleccionada sin reemplazo de una población finita de tamaño N , que contiene exactamente K elementos clasificados como éxitos y $N - K$ como fracasos. Este modelo es adecuado cuando las extracciones se realizan sin reemplazo, lo que implica que las probabilidades cambian en cada selección.

La función de masa de probabilidad está dada por:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}, \quad \text{con } \max(0, n - (N - K)) \leq x \leq \min(n, K)$$

donde:

- N : Tamaño total de la población.
- K : Número total de éxitos en la población.
- n : Tamaño de la muestra.
- x : Número de éxitos en la muestra.

Esta fórmula representa la proporción entre:

- las formas de seleccionar x éxitos de los K disponibles y $n - x$ fracasos de los $N - K$, y
- el total de formas posibles de seleccionar n elementos de una población de N individuos.

2.2.4 Distribución Poisson

La distribución de Poisson surge como límite de la binomial cuando el número de ensayos crece y la probabilidad de éxito en cada ensayo es pequeña, de modo que el producto np tiende a un valor finito λ . Modela procesos de “cuenta de eventos” que ocurren de forma aleatoria e independiente a tasa constante λ por unidad de tiempo o espacio. Entre sus propiedades más relevantes:

Propiedad de aditividad Si $X_1 \sim \text{Poisson}(\lambda_1)$ y $X_2 \sim \text{Poisson}(\lambda_2)$ son independientes, entonces $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$. Esto facilita la superposición de procesos de Poisson.

Proceso de Poisson El número de llegadas en intervalos de longitud t sigue $\text{Poisson}(\lambda t)$, y los tiempos entre eventos (intervalos interarribos) son exponenciales e independientes, con parámetro λ .

Usos y consideraciones Se emplea en telecomunicaciones (número de llamadas), biología (mutaciones), procesos de colas y confiabilidad. Su varianza igual a la media implica que modela bien fenómenos con dispersión equidispersa, pero no ajusta datos sobredispersos (varianza mayor que media) ni infradispersos (varianza menor).

2.2.5 Distribución Empírica Discreta

La distribución empírica discreta se construye a partir de un conjunto de observaciones o medidas $\{x_i\}$ y sus frecuencias relativas $\{p_i\}$. No obstante existir múltiples métodos de ajuste, en simulación se utiliza directamente para replicar la distribución muestral observada, sin asumir ninguna forma paramétrica.

Construcción de la CDF Se define la función de distribución acumulada

$$F(x_j) = \sum_{i: x_i \leq x_j} p_i,$$

que es una función escalonada. Para generar una muestra, se extrae $U \sim U(0, 1)$ y se asigna $X = x_j$ tal que

$$F(x_{j-1}) < U \leq F(x_j).$$

Este procedimiento reproduce exactamente las probabilidades empíricas.

Momentos y ajustes Los momentos de orden superior (asimetría, curtosis) se calculan igual que en cualquier discreta:

$$\mu = \sum_i x_i p_i, \quad \sigma^2 = \sum_i (x_i - \mu)^2 p_i, \quad \gamma_1 = \frac{\sum_i (x_i - \mu)^3 p_i}{\sigma^3}, \dots$$

Permite comparar la distribución empírica con distintos modelos teóricos (Chi-cuadrado, Kolmogorov–Smirnov) antes de decidir un ajuste paramétrico.

Aplicaciones prácticas Se usa para simular fenómenos donde se dispone de frecuencias observadas (encuestas, registros históricos) y no se desea imponer un modelo predefinido. Es especialmente útil en simulación de sistemas reales cuando la muestra histórica es representativa y de tamaño suficiente para captar la variabilidad del proceso.

2.3 Métodos

2.3.1 Método de Transformación Inversa

El método de transformación inversa es una técnica para generar variables aleatorias con una distribución específica, partiendo de números pseudoaleatorios uniformemente distribuidos en el intervalo $[0, 1]$. Se basa en la idea de aplicar la inversa de la función de distribución acumulada (CDF) de la variable deseada

2.3.2 Método de Rechazo

El método de rechazo es una técnica general utilizada para generar valores aleatorios que sigan una distribución de probabilidad objetivo $f(x)$, cuando no se dispone de un método directo para muestrear dicha distribución.

La idea consiste en utilizar otra distribución auxiliar o propuesta $g(x)$, que cumpla las siguientes condiciones:

- Es fácil de muestrear.
- Existe una constante $c > 0$ tal que:

$$f(x) \leq c \cdot g(x), \quad \text{para todo } x$$

El procedimiento es el siguiente:

1. Generar un valor x según la distribución propuesta $g(x)$.
2. Generar un número aleatorio uniforme $u \sim U(0, 1)$.
3. Aceptar x si:

$$u \leq \frac{f(x)}{c \cdot g(x)}$$

4. Si no se acepta, repetir desde el paso 1.

El valor aceptado x tendrá distribución $f(x)$.

Este método es especialmente útil cuando se conoce la función de masa (o densidad) de $f(x)$, pero no se tiene una forma directa de muestrear desde ella.

2.4 Métodos de Generación por Distribución

En esta sección se detalla cómo se implementaron los generadores para cada distribución a partir de números uniformes en $(0,1)$.

2.4.1 Distribución Uniforme

• Método de Transformación Inversa:

La función de distribución acumulada (CDF) de la uniforme continua está dada por:

$$F(x) = \frac{x - a}{b - a}, \quad x \in [a, b]$$

Invirtiendo esta expresión, se obtiene la fórmula para generar muestras a partir de un número aleatorio $U \sim U(0, 1)$:

$$X = a + (b - a) \cdot U$$

Este método es directo, exacto y computacionalmente eficiente, por lo que resulta ideal para esta distribución.

• Método de Rechazo:

Aunque la distribución uniforme permite una generación directa, se implementó este método con fines ilustrativos. Se definió una distribución propuesta $g(x)$ uniforme en un intervalo ampliado:

$$[c, d] = [a - (b - a), b + (b - a)]$$

La constante de aceptación es:

$$\text{aceptación} = \frac{b - a}{d - c} = \frac{b - a}{3(b - a)} = \frac{1}{3}$$

El algoritmo genera un candidato $y \in [c, d]$ y un número $u \sim U(0, 1)$. Se acepta el valor y si:

$$a \leq y \leq b \quad \text{y} \quad u < \frac{1}{3}$$

Este método tiene menor eficiencia, pero permite visualizar el funcionamiento del método de rechazo, que será útil para distribuciones más complejas donde no es posible aplicar transformación inversa.

2.4.2 Distribución Exponencial

- **Transformación Inversa:**

Este método se basa en invertir la función de distribución acumulada de la exponencial:

$$F(x) = 1 - e^{-\lambda x} \Rightarrow F^{-1}(u) = -\frac{1}{\lambda} \ln(1 - u)$$

Como $U \sim U(0, 1)$ y $1 - U \sim U(0, 1)$, se puede usar directamente:

$$X = -\frac{1}{\lambda} \ln(U)$$

Este valor X tiene distribución exponencial con parámetro λ . Es un método directo, eficiente y muy utilizado cuando se dispone de la función inversa de la CDF.

- **Método de Rechazo:**

En este caso se utiliza el propio soporte de la distribución como dominio de muestreo. Se define un rectángulo que contiene a la curva de densidad $f(x) = \lambda e^{-\lambda x}$, acotando su dominio en:

$$x \in [0, x_{\max}], \quad x_{\max} = \frac{-\ln(0.0001)}{\lambda}$$

Esta cota superior para x se elige para asegurar que $f(x)$ sea suficientemente pequeña fuera de ese rango (menos del 0.01% de probabilidad).

Se generan puntos uniformes (x, y) en el rectángulo:

$$x \sim U(0, x_{\max}), \quad y \sim U(0, \lambda)$$

El punto se acepta si:

$$y \leq f(x) = \lambda e^{-\lambda x}$$

De este modo, se obtiene un valor con la forma deseada de la distribución. Este método es útil cuando se desea evitar operaciones logarítmicas en algunos entornos computacionales o al trabajar con distribuciones sin inversa cerrada.

2.4.3 Distribución Gamma

- **Método de Rechazo:**

Se diferencian dos casos según el valor del parámetro α :

- **Caso $\alpha < 1$: Método de Aceptación-Rechazo Adaptado**

En este caso, se utiliza una transformación de variables basada en la relación entre la distribución Gamma y la distribución exponencial. El algoritmo es el siguiente:

1. Generar $u, v \sim U(0, 1)$
2. Calcular:

$$x = (-\ln u)^{1/\alpha}, \quad y = \exp(-x)$$

3. Aceptar x si $v \leq y$, y devolver x/β

Este método explota la forma de la densidad gamma para $\alpha < 1$, donde la función tiene una singularidad en cero y decae exponencialmente.

- **Caso $\alpha \geq 1$: Método de Marsaglia y Tsang (2000)**

Se emplea un algoritmo eficiente basado en una transformación de la normal estándar, conocido como el *método del impulso normal*. Se define:

$$d = \alpha - \frac{1}{3}, \quad c = \frac{1}{\sqrt{9d}}$$

Luego:

1. Generar $z \sim \mathcal{N}(0, 1)$, $u \sim U(0, 1)$
2. Calcular:

$$v = (1 + cz)^3$$

3. Aceptar si $v > 0$ y:

$$\ln u < \left(\frac{1}{2} z^2 + d - dv + d \ln v \right)$$

4. Devolver $x = \frac{dv}{\beta}$

Este método ofrece alta eficiencia y estabilidad numérica, especialmente cuando α es grande.

2.4.4 Distribución Normal

- **Aproximación mediante el Teorema Central del Límite (TCL):**

Aunque se incluyó bajo el nombre de “transformación inversa”, esta técnica no utiliza la función acumulada de la distribución normal. En cambio, se basa en la suma de variables uniformes para aproximar una distribución normal estándar. Consiste en generar 12 números aleatorios uniformes $U_i \sim U(0, 1)$ y luego calcular:

$$Z = \sum_{i=1}^{12} U_i - 6$$

Esta variable Z tiene aproximadamente distribución $\mathcal{N}(0, 1)$. Para obtener una normal general con media μ y desviación estándar σ , se aplica:

$$X = \mu + \sigma Z$$

Esta técnica es sencilla de implementar, aunque menos precisa que otros métodos cuando se requieren muestras con alta fidelidad estadística.

- **Método de Rechazo (Ahrens y Dieter):**

Se implementó una variante del método de rechazo optimizado para la distribución normal. Este método genera dos variables exponenciales y_1 y y_2 como:

$$y_1 = -\ln(U_1), \quad y_2 = -\ln(U_2)$$

donde $U_1, U_2 \sim U(0, 1)$. Luego se evalúa el criterio de aceptación:

$$y_2 \geq \frac{(y_1 - 1)^2}{2}$$

Si se cumple, se acepta y_1 como el valor absoluto de una muestra normal estándar, con signo aleatorio. Finalmente se transforma a la normal deseada:

$$X = \mu + \sigma \cdot Z \quad \text{donde} \quad Z = \pm y_1$$

Este método es eficiente y evita el uso de funciones trigonométricas (como en Box-Muller), siendo una buena alternativa para simulaciones donde se requiere generar grandes cantidades de datos normalmente distribuidos.

2.4.5 Distribución Pascal (Binomial Negativa)

- **Método de Rechazo:**

1. Se calcula una cota superior de la función de masa de probabilidad ($f_{\max}$) en un intervalo razonable. Para ello, se utiliza que el valor esperado es $\mathbb{E}[X] = \frac{r(1-p)}{p}$ y su desviación estándar $\sigma = \sqrt{\frac{r(1-p)}{p^2}}$, por lo que se elige:

$$x_{\max} = \lfloor \mathbb{E}[X] + 10 \cdot \sigma \rfloor$$

2. Evaluar la pmf para cada $x \in [0, x_{\max}]$ y encontrar:

$$f_{\max} = \max_{0 \leq x \leq x_{\max}} P(X = x)$$

3. Repetir hasta aceptar un valor:
 - (a) Generar $x \sim \mathcal{U}\{0, x_{\max}\}$
 - (b) Generar $y \sim \mathcal{U}(0, f_{\max})$
 - (c) Calcular $f(x) = P(X = x)$
 - (d) Aceptar x si $y \leq f(x)$

2.4.6 Distribución Binomial

• **Método de Rechazo:**

1. Se calcula una cota superior de la función de masa de probabilidad ($f_{\max}$) en un intervalo razonable. Para ello, se utiliza que el valor esperado es $\mathbb{E}[X] = n \cdot p$ y su desviación estándar $\sigma = \sqrt{n \cdot p \cdot (1 - p)}$, por lo que se elige:

$$x_{\max} = \lfloor \mathbb{E}[X] + 10 \cdot \sigma \rfloor$$

2. Evaluar la pmf para cada $x \in [0, x_{\max}]$ y encontrar:

$$f_{\max} = \max_{0 \leq x \leq x_{\max}} P(X = x)$$

3. Repetir hasta aceptar un valor:
 - (a) Generar $x \sim \mathcal{U}\{0, x_{\max}\}$
 - (b) Generar $y \sim \mathcal{U}(0, f_{\max})$
 - (c) Calcular $f(x) = P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$
 - (d) Aceptar x si $y \leq f(x)$

2.4.7 Distribución Hipergeométrica

• **Método de Rechazo:**

1. Se calcula una cota superior de la función de masa de probabilidad ($f_{\max}$) en un intervalo razonable. Para ello, se utiliza:

$$x_{\min} = \max(0, n - (N - K)), \quad x_{\max} = \min(n, K)$$

2. Evaluar la pmf para cada $x \in [x_{\min}, x_{\max}]$ y encontrar:

$$f_{\max} = \max_{x_{\min} \leq x \leq x_{\max}} P(X = x)$$

3. Repetir hasta aceptar un valor:
 - (a) Generar $x \sim \mathcal{U}\{x_{\min}, x_{\max}\}$
 - (b) Generar $y \sim \mathcal{U}(0, f_{\max})$
 - (c) Calcular $f(x) = P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}$
 - (d) Aceptar x si $y \leq f(x)$

2.4.8 Distribución de Poisson

• **Método de Rechazo:**

1. Para la distribución de Poisson, se define un conjunto de parámetros:

$$c = 0.767 - \frac{3.36}{\lambda}, \quad \beta = \frac{\pi}{\sqrt{3\lambda}}, \quad \alpha = \beta\lambda$$

y se calcula:

$$k = \ln(c) - \lambda - \ln(\beta)$$

2. Repetir hasta aceptar un valor:

- (a) Generar $u \sim U(0, 1)$
- (b) Calcular $x = \frac{\alpha - \ln(\frac{1-u}{u})}{\beta}$
- (c) Redondear x a $n = \lfloor x + 0.5 \rfloor$
- (d) Si $n \geq 0$, generar $v \sim U(0, 1)$
- (e) Calcular $y = \alpha - \beta x$
- (f) Evaluar:

$$\text{lhs} = y + \ln \left(\frac{v}{(1 + e^y)^2} \right)$$

y

$$\text{rhs} = k + n \ln(\lambda) - \ln(n!)$$

- (g) Aceptar n si $\text{lhs} \leq \text{rhs}$

2.4.9 Distribución Empírica Discreta

- **Método de Rechazo:**

1. Se evalúa el valor máximo de las probabilidades $p_{\max} = \max(p_1, p_2, \dots, p_k)$.
2. Repetir hasta aceptar un valor:
 - (a) Generar $idx \sim U(0, k - 1)$ (índice aleatorio de los valores).
 - (b) Generar $u \sim U(0, p_{\max})$ (valor aleatorio uniforme entre 0 y $p_{\max}$).
 - (c) Si $u \leq p_{idx}$, aceptar el valor x_{idx} y añadirlo a la lista de números generados.

2.5 Tests de Bondad de Ajuste

En esta sección se describen los tres tests de bondad de ajuste implementados para evaluar si una muestra de números pseudoaleatorios se ajusta a una distribución teórica específica.

2.5.1 Test de Chi-cuadrado (Chi-Square Test)

El test de Chi-cuadrado compara las frecuencias observadas en una muestra con las frecuencias esperadas según una distribución teórica.

- Se divide el rango de los datos en intervalos (o se agrupan los valores en el caso de variables discretas).
- Para cada intervalo, se cuenta cuántos datos caen en él (frecuencia observada) y se calcula cuántos deberían caer según la distribución teórica (frecuencia esperada).
- La estadística del test se calcula como:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

donde O_i es la frecuencia observada en el intervalo i , y E_i la frecuencia esperada.

- Se compara con una distribución χ^2 con $k - 1 - p$ grados de libertad, donde p es el número de parámetros estimados.

Es adecuado para datos agrupados (ya sean discretos o continuos) y requiere que las frecuencias esperadas sean suficientemente grandes (usualmente al menos 5).

2.5.2 Test de Kolmogorov-Smirnov (KS Test)

El test de Kolmogorov-Smirnov compara la función de distribución acumulada empírica (ECDF) de los datos con la función de distribución acumulada (CDF) de una distribución teórica continua.

- La estadística del test es:

$$D_n = \sup_x |F_n(x) - F(x)|$$

donde $F_n(x)$ es la ECDF de la muestra, y $F(x)$ la CDF de la distribución teórica.

- Se mide la mayor diferencia absoluta entre ambas funciones acumuladas.
- El valor calculado se compara con valores críticos tabulados para determinar si se rechaza la hipótesis nula.

Este test es válido solo para distribuciones continuas y no requiere agrupamiento de datos.

2.5.3 Test de Anderson-Darling (AD Test)

El test de Anderson-Darling es una mejora del test de Kolmogorov-Smirnov. También compara la ECDF con la CDF teórica, pero da más peso a las colas de la distribución.

- La estadística se calcula como:

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n [(2i - 1) (\ln F(X_i) + \ln(1 - F(X_{n+1-i})))]$$

donde $F(X)$ es la CDF de la distribución teórica y X_i son los datos ordenados.

- Se compara la estadística con valores críticos específicos para cada distribución.

Es más sensible que el KS test, especialmente en las colas, pero está implementado en `scipy` solamente para algunas distribuciones (como la normal y la exponencial).

3 Implementación

En esta sección se describe la implementación de los generadores de números pseudoaleatorios y las pruebas estadísticas utilizadas para evaluar su aleatoriedad.

- **Lenguaje:** Python 3.10.
- **Bibliotecas utilizadas:**
 - `collections`: para realizar cálculos sobre listas.
 - `math`: para realizar cálculos numéricos.
 - `matplotlib`: para graficar las distribuciones obtenidas.
 - `numpy`: para realizar cálculos y operaciones sobre los conjuntos de números.
 - `scipy.stats`: para obtener las funciones de masa y probabilidad de las distribuciones.
 - `tabulate`: para mostrar los resultados de los tests realizados.
- **Generadores:** Se utilizaron semillas para asegurar la reproducibilidad de la simulación. De ser deseado, las mismas pueden ser eliminadas.
 - Distribución Empírica Discreta: *semilla* = 42.
 - Resto de las Distribuciones: *semilla* = 12345.
- **Pruebas estadísticas realizadas:**
 - Prueba de bondad de ajuste de Chi-cuadrado
 - Prueba de Kolmogorov-Smirnov
 - Prueba de Anderson-Darling
- **Código disponible en:** <https://github.com/Luciocos/SimulacionTPs>

3.1 Código Distribución Uniforme

```
from scipy.stats import uniform
import numpy as np
from distributions.distribution import Distribution

class UniformDistribution(Distribution):
    dist_name = "uniform"
    dist_type = "continuous"

    def __init__(self, a: float, b: float, seed: int = 12345):
        super().__init__(seed)
        self.params = {"a": a, "b": b}

    @classmethod
    def get_instance(cls, a: float, b: float):
        if cls.instance is None:
            cls.instance = cls(a,b)
        return cls.instance

    def getParams(self):
        return self.params

    def get_expected_pdf(self):
```

```

a = self.params["a"]
b = self.params["b"]

x = np.linspace(a, b, 1000)
pdf = uniform.pdf(x, a, b - a)

return x, pdf

def randomFromInverseTransform(self):
    a = self.params['a']
    b = self.params['b']
    r = self.rng.random()
    x = a + (b-a) * r
    self.inverse_transform_generated_numbers.append(x)

def randomFromRejectionMethod(self):
    a = self.params['a']
    b = self.params['b']
    c = a - (b - a)
    d = b + (b - a)
    acceptance = (b - a) / (d - c)

    while True:
        y = c + (d - c) * self.rng.random()
        u = self.rng.random()
        if a <= y <= b and u < acceptance:
            self.rejection_method_generated_numbers.append(y)
            break

```

3.2 Código Distribución Normal

```

import math
import numpy as np
from scipy.stats import norm
from distributions.distribution import Distribution

class NormalDistribution(Distribution):
    dist_name = "normal"
    dist_type = "continuous"

    def __init__(self, mu, sigma, seed:int =12345):
        super().__init__(seed)
        self.params = {"mu": mu, "sigma": sigma}

    def getParams(self):
        return self.params

    @classmethod
    def get_instance(cls, mu = 0, sigma = 1):
        if cls.instance is None:
            cls.instance = cls(mu, sigma)
        return cls.instance

    def get_expected_pdf(self):
        mu = self.params["mu"]
        sigma = self.params["sigma"]

        x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)
        pdf = norm.pdf(x, mu, sigma)

```

```

    return x, pdf

def randomFromInverseTransform(self): # en realidad no es por el método de la transformada inversa
    mu = self.params['mu']
    sigma = self.params['sigma']
    total = 0
    for _ in range(12):
        r = self.rng.random()
        total += r
    z = total - 6

    self.inverse_transform_generated_numbers.append(mu + sigma * z)

def randomFromRejectionMethod(self):
    mu = self.params['mu']
    sigma = self.params['sigma']
    while True:
        u1 = self.rng.random()
        u2 = self.rng.random()
        y1 = - math.log(u1)
        y2 = - math.log(u2)

        aux = (y1 - 1)**2 / 2
        if (y2 >= aux):
            abs_z = y1
            z = abs_z if self.rng.random() >= 0.5 else -abs_z
            x = sigma * z + mu
            self.rejection_method_generated_numbers.append(x)
            break

```

4 Resultados y Análisis

En esta sección se presentan los resultados de las pruebas aplicadas a los distintos métodos de generación de números aleatorios para varias distribuciones. Se incluyen los resultados estadísticos y las visualizaciones comparativas de las distribuciones obtenidas frente a las distribuciones teóricas esperadas.

4.1 Parámetros utilizados para cada Distribución

- Uniforme: $a = 0 \parallel b = 5$
- Normal: $\mu = 25 \parallel \sigma = 4$
- Exponencial: $\lambda = 0.2$
- Binomial: $n = 10 \parallel p = 0.5$
- Poisson: $\lambda = 5$
- Empírica Discreta: Valores = [1, 2, 3, 4, 5] $\parallel$ Probabilidades = [0.1, 0.2, 0.3, 0.2, 0.2]
- Gamma: $\alpha = 2 \parallel \beta = 2$
- Pascal: $r = 5 \parallel p = 0.5$
- Hipergeométrica: $N = 50 \parallel K = 10 \parallel n = 5$

4.2 Resultados de Pruebas Estadísticas

El resultado de cada prueba puede ser *Aprobado* o *Rechazado*, dependiendo de si los datos generados cumplen con los criterios establecidos por la prueba correspondiente. En los casos en que una prueba no haya sido aplicada (por no ser adecuada para ese tipo de distribución o por limitaciones técnicas), se indica con un guion (-) en la celda correspondiente.

Además se reservan dos columnas para expresar la media y el desvío estándar observados en el conjunto de números generados.

Distribución	Prueba de Bondad de Ajuste χ^2	Kolmogorov Smirnov	Anderson-Darling	Media	Desvío Estándar
Normal - Método Rechazo	Aprobado	Aprobado	Aprobado	24.97	3.97
Normal - Transformada Inversa	Aprobado	Aprobado	Aprobado	24.89	3.97
Exponencial - Método Rechazo	Aprobado	Aprobado	Aprobado	4.93	4.93
Exponencial - Transformada Inversa	Aprobado	Aprobado	Aprobado	5.01	5.04
Uniforme - Método Rechazo	Aprobado	Aprobado	-	24.59	14.27
Uniforme - Transformada Inversa	Aprobado	Aprobado	-	24.66	14.41
Binomial - Método Rechazo	Aprobado	-	-	4.99	1.59
Poisson - Método Rechazo	Aprobado	-	-	5.01	2.22
Empírica Discreta - Método Rechazo	Aprobado	-	-	3.20	1.26

Table 1: Resultados de pruebas de bondad de ajuste y medidas estadísticas básicas.

4.3 Comparación Visual de Distribuciones

A continuación, se presentan las comparaciones gráficas entre las distribuciones generadas y las distribuciones teóricas esperadas para cada caso de estudio. Las imágenes muestran histogramas superpuestos o curvas de densidad que permiten visualizar la calidad del ajuste.




Figure 1: Distribuciones uniformes generadas utilizando los métodos de la transformación inversa y el del rechazo.




Figure 2: Distribuciones exponenciales generadas utilizando los métodos de la transformación inversa y el del rechazo.




Figure 3: Distribución gamma generada utilizando el método del rechazo.




Figure 4: Distribuciones normales generadas utilizando los métodos de la transformación inversa y el del rechazo.




Figure 5: Distribución Pascal generada utilizando el método del rechazo.




Figure 6: Distribución binomial generada utilizando el método del rechazo.




Figure 7: Distribución hipergeométrica generada utilizando el método del rechazo.




Figure 8: Distribución Poisson generada utilizando el método del rechazo.




Figure 9: Distribución empírica discreta generada utilizando el método del rechazo.

5 Conclusión

En conclusión, este trabajo ha implementado en Python generadores de números pseudoaleatorios para distribuciones continuas (uniforme, exponencial, gamma y normal) y discretas (Pascal, binomial, hipergeométrica, Poisson y empírica), apoyándose en los métodos de transformación inversa y de rechazo. Cada algoritmo fue sometido a pruebas de bondad de ajuste (Chi-cuadrado, Kolmogórov–Smirnov y Anderson–Darling), que confirmaron la correspondencia de las muestras con sus respectivas distribuciones teóricas.

La transformación inversa se reveló especialmente directa y eficiente cuando la función inversa de la CDF está disponible (por ejemplo, en las distribuciones uniforme y exponencial), mientras que el rechazo proporcionó la versatilidad necesaria para aquellas distribuciones sin inversa cerrada (gamma y las discretas). En todos los casos, las medias y varianzas muestrales se alinearon estrechamente con los valores teóricos.

En definitiva, ambos métodos quedan validados como herramientas robustas para simulaciones y análisis estadísticos. Sin embargo, su aplicación debe ir siempre acompañada de tests de bondad de ajuste que garanticen la fidelidad, precisión y reproducibilidad de los datos generados, especialmente en estudios cuantitativos donde estos atributos son críticos.

Agradecimientos

Agradecemos a los profesores Juan I. Torres y Jorge A. Flamini por su orientación, y a la Universidad Tecnológica Nacional - FRRO por el apoyo brindado.

References

- [1] Ross, S. M. *Introduction to Probability and Statistics for Engineers and Scientists*. Academic Press.
- [2] Python Software Foundation. <https://docs.python.org/3/>
- [3] Overleaf. *Plantilla Latex Cornell University*.
<https://es.overleaf.com/latex/templates-style-and-template-for-preprints-arxiv-bio-arxiv/pkzcrhzcxdxmc>
- [4] *Acceptance-Rejection Method*.
<https://www.columbia.edu/~ks20/4703-Sigman/4703-07-Notes-ARM.pdf>
- [5] Baeldung. *Sampling From the Exponential Distribution*.
<https://www.baeldung.com/cs/sampling-exponential-distribution>
- [6] Cosmic Coding. *A visual tutorial of Rejection Sampling*.
https://cosmiccoding.com.au/tutorials/rejection_sampling/
- [7] Wikipedia. *Rejection sampling*.
https://en.wikipedia.org/wiki/Rejection_sampling
- [8] Arize. *Kolmogorov Smirnov Test for AI: When and Where To Use It*.
<https://arize.com/blog-course/kolmogorov-smirnov-test/>
- [9] Medium. *La prueba de Kolmogorov-Smirnov en Python*.
<https://medium.com/@petredelfina/la-prueba-de-kolmogorov-smirnov-en-python-fbe1c5e9d3d5>
- [10] SciPy. *scipy.stats*.
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.anderson.html>
- [11] Naylor, T. H. *Técnicas de Simulación en Computadoras*, Capítulo 4: Generación de valores de las variables estocásticas empleadas en simulación.
<https://drive.google.com/file/d/1587rdkn8Qed6N9DdTYskRNEBKGDvhea/view>